Gán nhãn từ loại
Part of Speech tagging

Giảng viên: TS. Phạm Đình Phong

Email: phongpd@utc.edu.vn

ĐT: 0972481813

Gán nhãn từ loại

- Định nghĩa: .
  - Gán nhãn từ loại (Part of Speech tagging – POS tagging): mỗi từ trong câu được gán nhãn thẻ từ loại tương ứng của nó
  - Vào: một đoạn văn bản đã tách từ + tập nhãn
  - Ra: cách gán nhãn chính xác nhất
  - Gán nhãn làm cho việc phân tích văn bản dễ dàng hơn

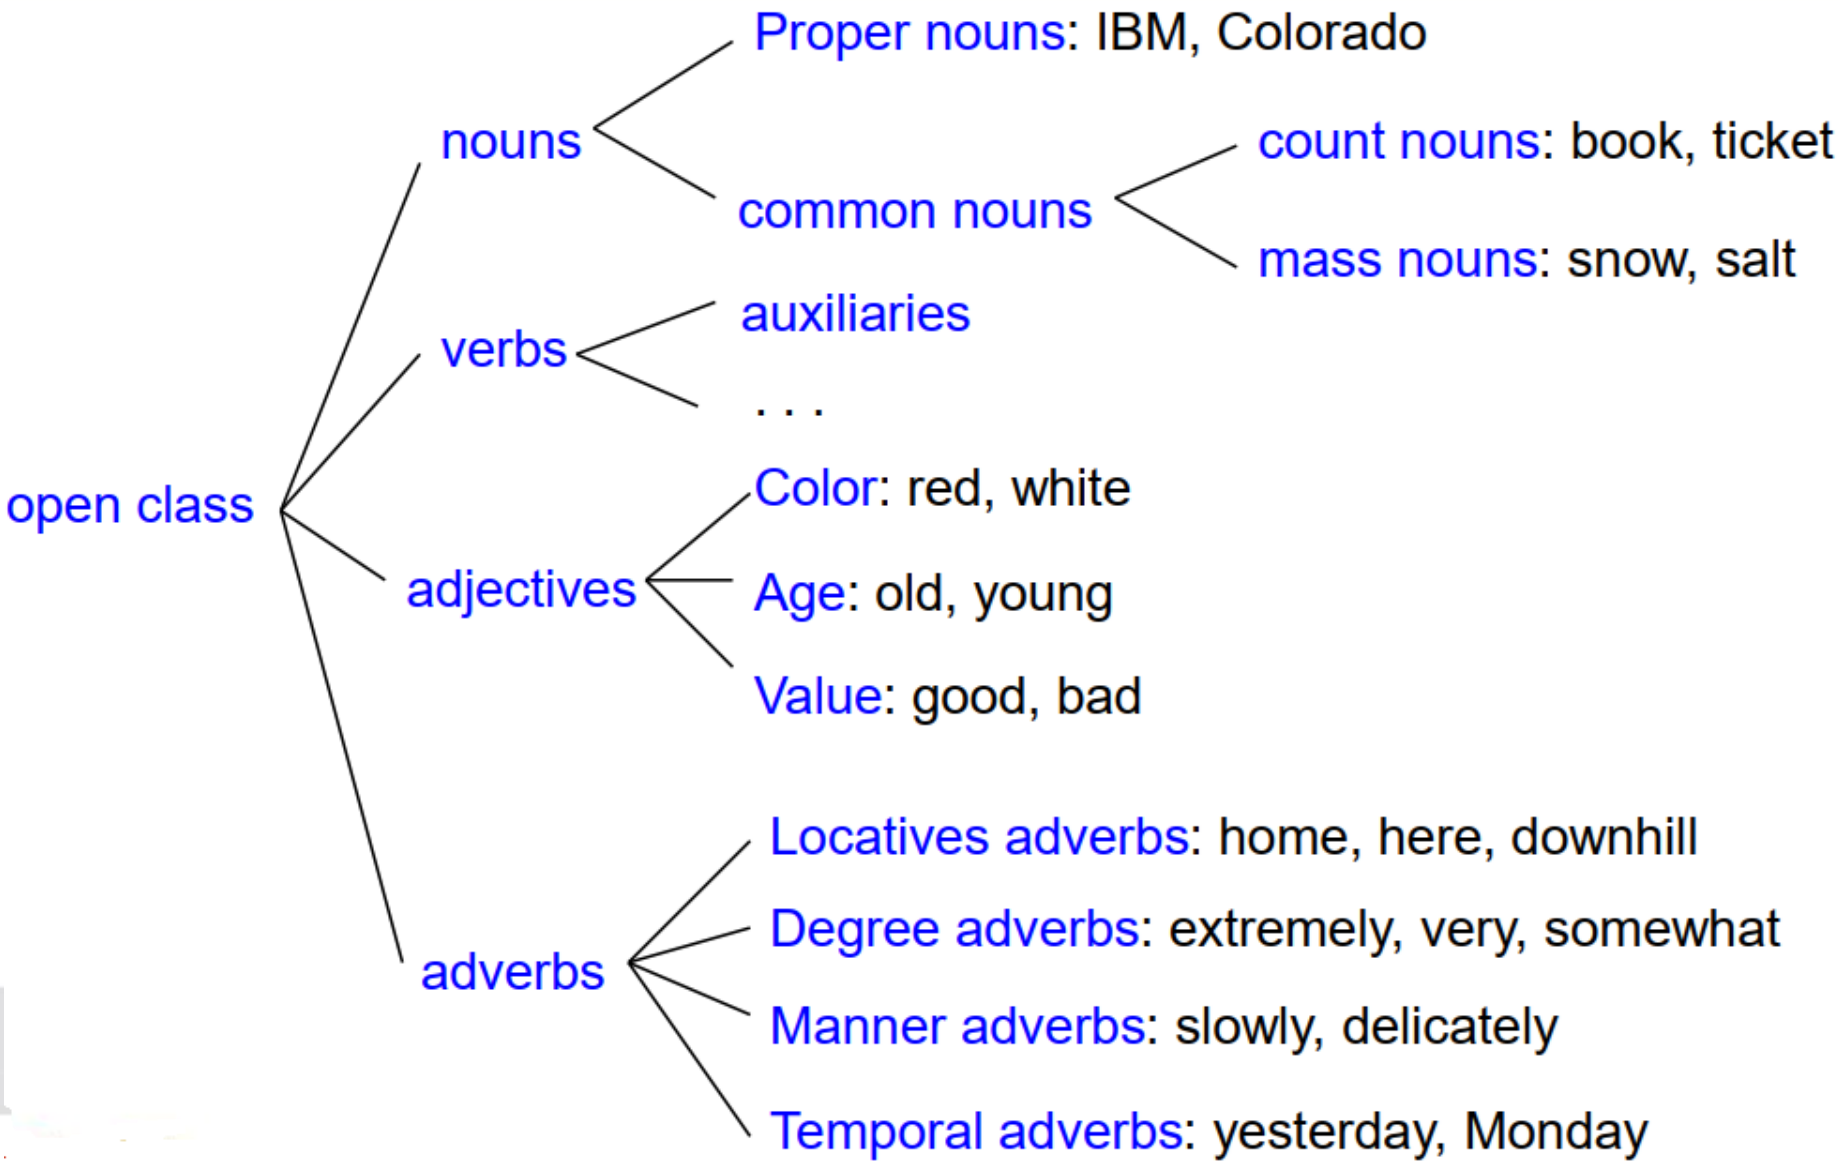
Tại sao cần gán nhãn

- Dễ thực hiện: có thể thực hiện bằng nhiều phương pháp khác nhau
  - Các phương pháp sử dụng ngữ cảnh có thể đem lại kết quả tốt
  - Mặc dù nên thực hiện bằng phân tích văn bản
- Các ứng dụng:
  - Text-to-speech: record - N: [‘reko:d], V: [ri’ko:d]; lead – N [led], V: [li:d], separate – Adj: [ˈsep.ər.ət], V: [ˈsep.ər.eɪt]
  - Tiền xử lý cho PTCP. PTCP thực hiện việc gán nhãn tốt hơn nhưng đắt hơn
  - Nhận dạng tiếng nói, PTCP, tìm kiếm, ...
- Dễ đánh giá (có bao nhiêu thẻ được gán nhãn đúng?)

Tập từ loại tiếng Anh

- **Lớp đóng** (các từ chức năng): số lượng cố định
  - Giới từ (Prepositions): on, under, over,…
  - Tiểu từ (Particles): abroad, about, around, before, in, instead, since, without,…
  - Mạo từ (Articles): a, an, the
  - Liên từ (Conjunctions): and, or, but, that, …
  - Đại từ (Pronouns): you, me, I, your, what, who, …
  - Trợ động từ (Auxiliary verbs): can, will, may, should, …
- **Lớp mở**: có thể có thêm từ mới

Lớp từ mở trong tiếng Anh



Tập nhãn cho tiếng Anh

- Tập ngữ liệu Brown: 87 nhãn
- 3 tập thường được sử dụng:
  - Nhỏ: 45 nhãn - Penn treebank (slide sau)
  - Trung bình: 61 nhãn, British national corpus
  - Lớn: 146 nhãn, C7

Tag	Description	Example	Tag	Description	Example
CC	Coordin. Conjunction	*and, but, or*	SYM	Symbol	+,%, &
CD	Cardinal number	*one, two, three*	TO	"to"	*to*
DT	Determiner	*a, the*	UH	Interjection	*ah, oops*
EX	Existential 'there'	*there*	VB	Verb, base form	*eat*
FW	Foreign word	*mea culpa*	VBD	Verb, past tense	*ate*
IN	Preposition/sub-conj	*of, in, by*	VBG	Verb, gerund	*eating*
JJ	Adjective	*yellow*	VBN	Verb, past participle	*eaten*
JJR	Adj., comparative	*bigger*	VBP	Verb, non-3sg pres	*eat*
JJS	Adj., superlative	*wildest*	VBZ	Verb, 3sg pres	*eats*
LS	List item marker	*1, 2, One*	WDT	Wh-determiner	*which, that*
MD	Modal	*can, should*	WP	Wh-pronoun	*what, who*
NN	Noun, sing. or mass	*llama*	WP$	Possessive wh-	*whose*
NNS	Noun, plural	*llamas*	WRB	Wh-adverb	*how, where*
NNP	Proper noun, singular	*IBM*	$	Dollar sign	*$*
NNPS	Proper noun, plural	*Carolinas*	#	Pound sign	*#*
PDT	Predeterminer	*all, both*	"	Left quote	(' or ")
POS	Possessive ending	*'s*	"	Right quote	(' or ")
PP	Personal pronoun	*I, you, he*	(	Left parenthesis	([, (, {, <)
PP$	Possessive pronoun	*your, one's*	)	Right parenthesis	( ],), }, >)
RB	Adverb	*quickly, never*	,	Comma	,
RBR	Adverb, comparative	*faster*	.	Sentence-final punc	(. ! ?)
RBS	Adverb, superlative	*fastest*	:	Mid-sentence punc	(: ; ... – -)
RP	Particle	*up, off*			

Tag	Description	Example
CC	Coordin. Conjunction	*and, but, or*
CD	Cardinal number	*one, two, three*
DT	Determiner	*a, the*
EX	Existential 'there'	*there*
FW	Foreign word	*mea culpa*
IN	Preposition/sub-conj	*of, in, by*
JJ	Adjective	*yellow*
JJR	Adj., comparative	*bigger*
JJS	Adj., superlative	*wildest*
LS	List item marker	*1, 2, One*
MD	Modal	*can, should*
NN	Noun, sing. or mass	*llama*
NNS	Noun, plural	*llamas*
NNP	Proper noun, singular	*IBM*
NNPS	Proper noun, plural	*Carolinas*
PDT	Predeterminer	*all, both*
POS	Possessive ending	*'s*
PP	Personal pronoun	*I, you, he*
PP$	Possessive pronoun	*your, one's*
RB	Adverb	
RBR	Adverb, co	
RBS	Adverb, su	
RP	Particle	

Tag	Description	Example
SYM	Symbol	+,%, &
TO	"to"	*to*
UH	Interjection	*ah, oops*
VB	Verb, base form	*eat*
VBD	Verb, past tense	*ate*
VBG	Verb, gerund	*eating*
VBN	Verb, past participle	*eaten*
VBP	Verb, non-3sg pres	*eat*
VBZ	Verb, 3sg pres	*eats*
WDT	Wh-determiner	*which, that*
WP	Wh-pronoun	*what, who*
WP$	Possessive wh-	*whose*
WRB	Wh-adverb	*how, where*
$	Dollar sign	*$*
#	Pound sign	*#*
"	Left quote	(' or ")
"	Right quote	(' or ")
(	Left parenthesis	([, (, {, <)
)	Right parenthesis	( ],), }, >)

I know that blocks the sun.
He always books the violin concert tickets early.
He says that book is interesting.

Penn Treebank

- Khó khăn trong gán nhãn từ loại?

… là xử lý nhập nhằng

Các cách tiếp cận

- **Sử dụng HMM:** "Sử dụng tất cả thông tin đã có và đoán"
- **Dựa trên chuyển đổi**: "Đoán trước, sau đó có thể thay đổi"

→ Có thể dựa trên ràng buộc ngữ pháp để loại trừ những khả năng sai"

Gán nhãn dựa trên xác suất

- Cho câu hoặc 1 xâu các từ, gán nhãn từ loại thường xảy ra nhất cho các từ trong xâu đó.
- Cách thực hiện:
  - Hidden Markov model (HMM):
    - Chọn thẻ từ loại làm tối đa xác suất:

P(từ|từ loại)•P(từ loại| n từ loại phía trước)

The/DT grand/JJ jury/NN commented/VBD on/IN a/DT number/NN of/IN other/JJ topics/NNS ./.

$\Rightarrow$ P(jury|NN) = 1/2

Gán nhãn dựa trên xác suất

- Cho câu hoặc 1 xâu các từ, gán nhãn từ loại thường xảy ra nhất cho các từ trong xâu đó.
- Cách thực hiện:
  - Hidden Markov model (HMM):
    - Một số xác suất có thể tính được từ tập ngữ liệu
    - Xác suất nhãn t_k theo sau nhãn t_i $P(t_k|t_j) = \frac{C(t_j, t_k)}{C(t_j)}$
    - Xác suất nhãn t_j là từ w_i $P(w_i|t_j) = \frac{C(w_i, t_j)}{C(t_j)}$

Mô hình Markov ẩn (HMM)

- Theo công thức Bayes: $$P(A \mid B) = \frac{P(B \mid A) \cdot P(A)}{P(B)}$$

- Xác suất gán nhãn cho cả xâu được tính như sau:

$$P(t_1^n | w_1^n) = \frac{P(w_1^n | t_1^n) P(t_1^n)}{P(w_1^n)}$$

- Lựa chọn phương án gán nhãn làm cực đại hóa xác suất gán nhãn cho xâu

$$\underset{t_1^n}{\operatorname{argmax}}\, P(t_1^n | w_1^n) = \underset{t_1^n}{\operatorname{argmax}} \frac{P(w_1^n | t_1^n) P(t_1^n)}{P(w_1^n)}$$

$$= \underset{t_1^n}{\operatorname{argmax}}\, P(w_1^n | t_1^n) P(t_1^n)$$

Mô hình Markov ẩn (HMM)

- Ta có:

$$P(w_1^n|t_1^n)P(t_1^n) = \prod_1^n P(w_i|t_1^n) * P(t_n|t_1^{n-1}) * P(t_{n-1}|t_1^{n-2}) * \ldots * P(t_2|t_1)$$

- Giả thuyết Markov: Nhãn của từ chỉ phụ thuộc vào nhãn của từ trước đó

$$P(w_1^n|t_1^n)P(t_1^n) = \prod_1^n P(w_i|t_i) * P(t_n|t_{n-1}) * P(t_{n-1}|t_{n-2}) * \ldots * P(t_2|t_1)$$

$$= \prod_1^n (P(w_i|t_i) * P(t_i|t_{i-1}))$$

- Phương án gán nhãn

$$\underset{t_1^n}{\operatorname{argmax}}\, P(w_1^n|t_1^n)P(t_1^n) = \underset{t_1^n}{\operatorname{argmax}} \prod_1^n (P(w_i|t_i) * P(t_i|t_{i-1}))$$

Gán nhãn HMM

- **Công thức Bigram HMM**: chọn t_i cho w_i có nhiều khả năng nhất khi biết t_{i-1} và w_i

$$t_i = \text{argmax}_j \, P(t_j \mid t_{i-1}, w_i) \qquad (1)$$

- **Giả thiết đơn giản hóa HMM**: vấn đề gán nhãn có thể giải quyết bằng cách dựa trên các từ và thẻ từ loại bên cạnh nó

$$t_i = \text{argmax}_j \, P(t_j \mid t_{j-1}) P(w_i \mid t_j) \qquad (2)$$

xs chuỗi thẻ (các thẻ đồng xuất hiện)

xs từ thường xuất hiện với thẻ tj

Ví dụ

- 1. Secretariat/NNP is/VBZ expected/VBN to/TO race/VB tomorrow/NN
- 2. People/NNS continue/VBP to/TO inquire/VB the/DT reason/NN for/IN the/DT race/NN for/IN outer/JJ space/NN
- Không thể đánh giá bằng cách chỉ đếm từ trong tập ngữ liệu (và chuẩn hóa)
- Động từ theo sau TO nhiều hơn 1 danh từ (to race, to walk). Nhưng 1 danh từ cũng có thể theo sau TO (run to school)

Gán nhãn cho một từ theo HMM

- Xác suất từ loại t_i khi biết từ loại trước đó

$$P(t_i|t_{i-1}) = \frac{C(t_{i-1},t_i)}{C(t_{i-1})}$$

- Ví dụ trong tập dữ liệu mẫu MD xuất hiện 13124 lần, trong đó có 10471 lần sau nó là một động từ thì

$$P(VB|MD) = \frac{C(MD,VB)}{C(MD)} = \frac{10471}{13124} = .80$$

- Xác suất từ là w_i khi biết từ loại là t_i: $P(w_i|t_i) = \frac{C(t_i,w_i)}{C(t_i)}$

- Ví dụ trong tập dữ liệu mẫu MD xuất hiện 13124 lần trong đó có 4046 lần là từ will thì

$$P(will|MD) = \frac{C(MD,will)}{C(MD)} = \frac{4046}{13124} = .31$$

Ví dụ

- Giả sử chúng ta có tất cả các từ loại trừ từ race
- Chỉ nhìn vào từ đứng trước (bigram):

  to/TO race/??? NN or VB?

  the/DT race/???

- Áp dụng (2): $t_i = \text{argmax}_j P(t_j \mid t_{i-1}) P(w_i \mid t_j)$
- Chọn thẻ có xác suất lớn hơn giữa 2 xác suất:

  P(VB|TO)P(race|VB) hoặc P(NN|TO)P(race|NN)

  xác suất của 1 từ là race khi biết từ loại là VB.

Ví dụ

- Tính xác suất

  Xét P(VB|TO) và P(NN|TO)

- Từ tập ngữ liệu Brown

  P(NN|TO) = .021

  P(VB|TO) = .340

  P(race|NN) = 0.00041

  P(race|VB) = 0.00003

- P(VB|TO)P(race|VB) = 0.00001
- P(NN|TO) P(race|NN) = 0.000007

  → race cần phải là động từ nếu đi sau “TO”

Bài tập

- I know that blocks the sun.
- He always books the violin concert tickets early.
- He says that book is interesting.
- I/PP know/VBP that/WDT blocks/VBZ the/DT sun/NN.
- He/PP always/RB books/VBZ the/DT violin/NN concert/NN tickets/NNS early/RB.
- He/PP says/VBZ that/WDT book/NN is/VBZ interesting/JJ.
- I know that block blocks the sun.
- I/PP know/VBP that/DT block/NN blocks/NNS?VBZ? the/DT sun/NN.

Mô hình HMM đầy đủ

- Chúng ta cần tìm chuỗi thẻ tốt nhất cho toàn xâu
- Cho xâu từ *W*, cần tính chuỗi từ loại có xác suất lớn nhất

$$\hat{t}_1^n = \underset{t_1^n}{\operatorname{argmax}} P(t_1^n | w_1^n)$$

$$\hat{t}_1^n = \underset{t_1^n}{\operatorname{argmax}} \frac{P(w_1^n | t_1^n) P(t_1^n)}{P(w_1^n)}$$

$$\hat{t}_1^n = \underset{t_1^n}{\operatorname{argmax}} P(w_1^n | t_1^n) P(t_1^n)$$

- Trong đó giả thuyết

$$P(w_1^n | t_1^n) \approx \prod_{i=1}^{n} P(w_i | t_i)$$

$$P(t_1^n) \approx \prod_{i=1}^{n} P(t_i | t_{i-1})$$

Mô hình HMM đầy đủ

- Tóm lại giải pháp gán nhãn cho một chuỗi theo mô hình HMM làm tối đa hóa xác suất theo công thức

$$\hat{t}_1^n = \underset{t_1^n}{\operatorname{argmax}} P(t_1^n | w_1^n) \approx \underset{t_1^n}{\operatorname{argmax}} \prod_{i=1}^{n} \overbrace{P(w_i|t_i)}^{\text{emission}} \overbrace{P(t_i|t_{i-1})}^{\text{transition}}$$

Mở rộng sử dụng luật chuỗi

- Sử dụng quan hệ xác suất từ tập ngữ liệu để đánh giá xác suất:

P(A,B) = P(A|B)P(B) = P(B|A)P(A)

P(A,B,C) = P(B,C|A)P(A) = P(C|A,B)P(B|A)P(A)

= P(A)P(B|A)P(C|A,B)

P(A,B,C,D, …) = P(A)P(B|A)P(C|A,B)P(D|A,B,C, ...)

$$P(T)P(W \mid T) = \prod_{i=1}^{n} P(w_i \mid w_1 t_1 \ldots w_{i-1} t_{i-1} t_i) P(t_i \mid w_1 t_1 \ldots w_{i-1} t_{i-1})$$

pr từ

lịch sử nhãn

trong đó T = t_1, t_2, …, t_n

Giả thiết Trigram

- Xác suất 1 từ chỉ phụ thuộc vào nhãn của nó

$$P(w_i \mid w_1 t_1 \ldots t_{i-1} t_i) = P(w_i \mid t_i)$$

- Ta lấy lịch sử nhãn thông qua 2 nhãn gần nhất (trigram: 2 nhãn gần nhất + nhãn hiện tại)

$$P(t_i \mid w_1 t_1 \ldots t_{i-1}) = P(t_i \mid t_{i-2} t_{i-1})$$

- Thay vào công thức

$$P(T)P(W|T) =$$

$$P(t_1)P(t_2 \mid t_1)\prod_{i=3}^{n} P(t_i \mid t_{i-2} t_{i-1})[\prod_{i=1}^{n} P(w_i \mid t_i)]$$

Đánh giá xác suất

- Sử dụng quan hệ xác suất từ tập ngữ liệu để đánh giá xác suất:

$$P(t_i \mid t_{i-1}t_{i-2}) = \frac{c(t_{i-2}t_{i-1}t_i)}{c(t_{i-2}t_{i-1})}$$

$$P(w_i \mid t_i) = \frac{c(w_i, t_i)}{c(t_i)}$$

Bài toán

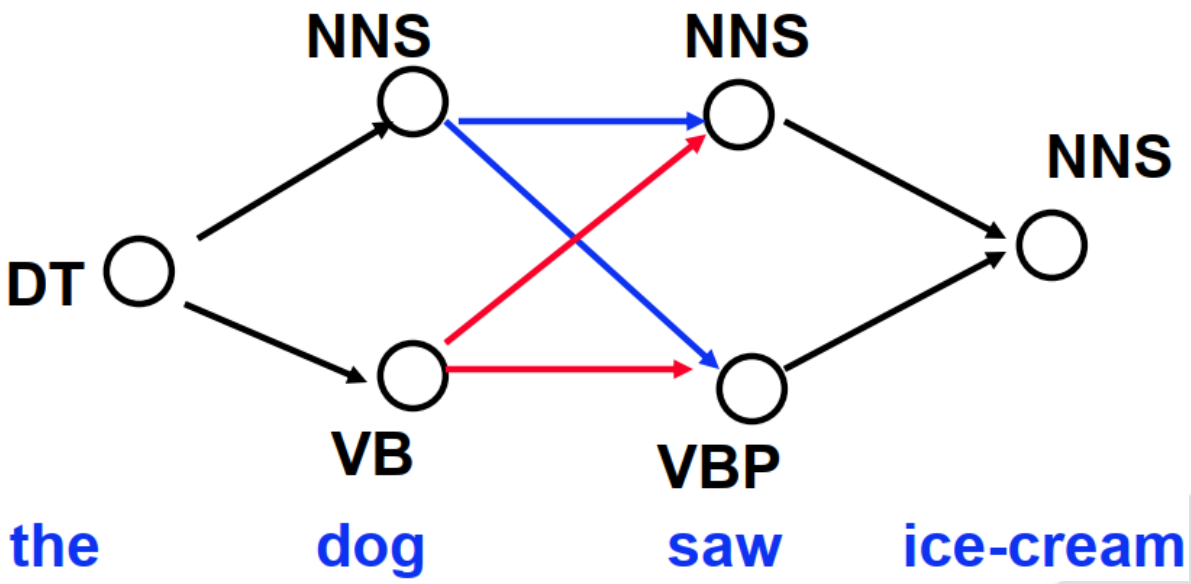
- Cần giải quyết

$$\hat{T} = \arg\max_{T \in \tau} P(T)P(W \mid T)$$

- Bây giờ ta có thể tính được tất cả các tích $P(T)P(W|T)$

Ví dụ

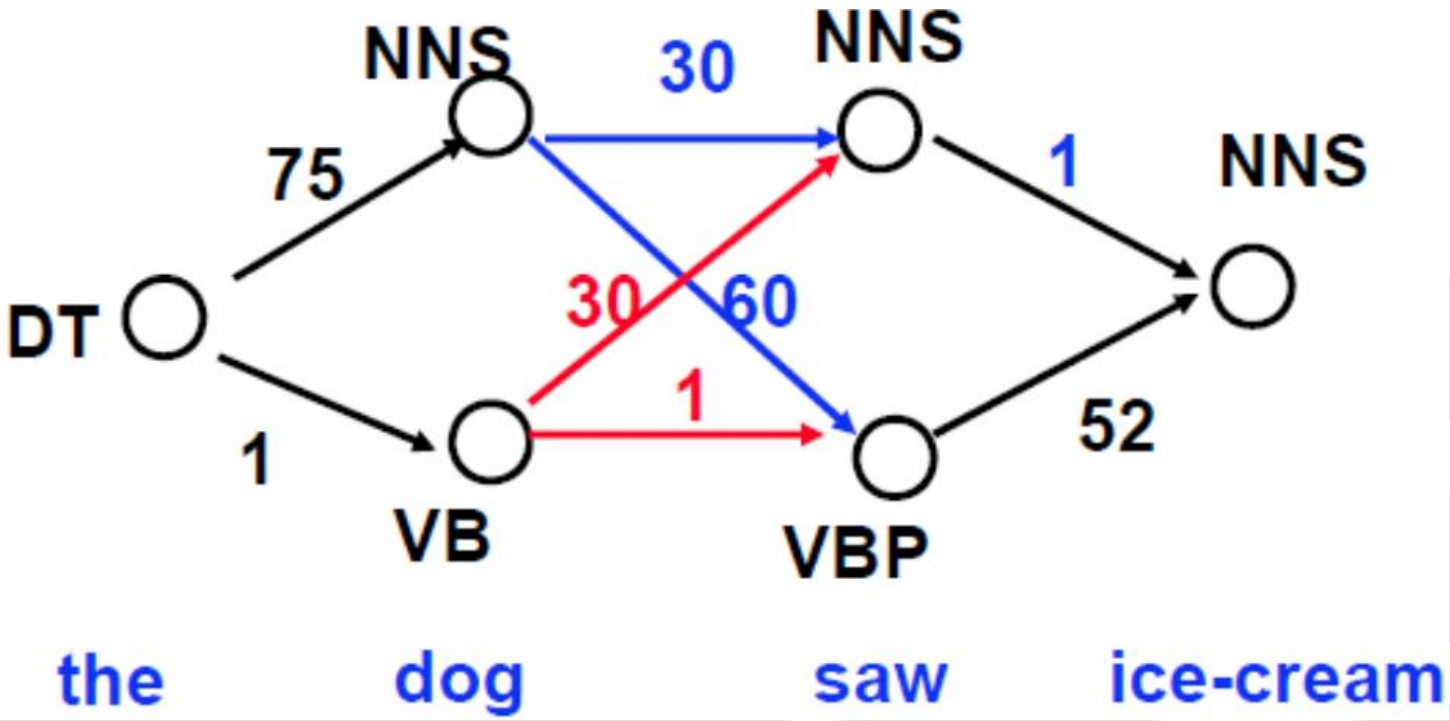
- Cần giải quyết



- Tìm đường đi tốt nhất?

Ví dụ

$$P(t_1)P(t_2 \mid t_1)\prod_{i=3}^{n} P(t_i \mid t_{i-2}t_{i-1})[\prod_{i=1}^{n} P(w_i \mid t_i)]$$



Cách tìm đường đi có điểm cao nhất

- Sử dụng tìm kiếm kiểu best-first (A*)
  - 1. Tại mỗi bước, chọn *k* giá trị tốt nhất (). Mỗi giá trị trong *k* giá trị này ứng với 1 khả năng kết hợp nhãn của tất cả các từ
  - 2. Khi gán từ tiếp theo, tính lại xác suất. Quay lại bước 1
- **Ưu điểm**: nhanh (không cần kiểm tra tất cả các khả năng kết hợp, chỉ k cái tiềm năng nhất)
- **Nhược điểm**: có thể không trả về kết quả tốt nhất mà chỉ chấp nhận được

Độ chính xác

- > 96%
- Cách đơn giản nhất? 90%
  - Gán mỗi từ với từ loại thường xuyên nhất của nó
  - Gán từ chưa biết = danh từ
- Người: 97%+/- 3%; nếu có thảo luận: 100%

Một số công cụ gán nhãn từ loại

- CVAT: công cụ mã nguồn mở được phát triển bởi Intel.
- Labelbox: một nền tảng data labeling miễn phí với giao diện người dùng kéo thả trực quan.
- JVnTagger: công cụ gán nhãn từ loại tiếng Việt dựa trên Conditional Random Fields (Lafferty et al., 2001) và Maximum Entropy (Nigam et al., 1999)
- VnCoreNLP