Phân tích cú pháp xác suất
Probabilistic parsing

Giảng viên: TS. Phạm Đình Phong

Email: phongpd@utc.edu.vn

ĐT: 0972481813

Làm cách nào chọn cây đúng?

- Ví dụ:
  - I saw a man with a telescope.
- Khi số luật tăng, khả năng nhập nhằng tăng
- Tập luật NYU: bộ PTCP Apple pie : 20,000-30,000 luật cho tiếng Anh
- Lựa chọn luật: V DT NN PP

1) VP → V NP PP

   NP → DT NN

2) VP → V NP

   NP → DT NN PP

Kết hợp từ (bigrams pr)

- Ví dụ:
  - Eat ice-cream (high frequency)
  - Eat John (low, except on Survivor)
- Nhược điểm:
  - P(John decided to bake a) có xác suất cao
  - Xét: $P(w_3) = P(w_3|w_2w_1)=P(w_3|w_2)P(w_2|w_1)P(w_1)$
  - Giả thiết này quá mạnh: chủ ngữ có thể quyết định bổ ngữ trong câu
    - Clinton admires honesty

  → Sử dụng cấu trúc ngữ pháp để dừng việc lan truyền
- Xét Fred watered his mother's small garden. Từ garden có ảnh hưởng như thế nào?
  - P(garden|mother's small) thấp ⇒ mô hình trigram không tốt
  - P(garden | X là thành phần chính của bổ ngữ cho động từ to water) cao hơn

  → Sử dụng bigram + quan hệ ngữ pháp

Kết hợp từ (bigrams pr)

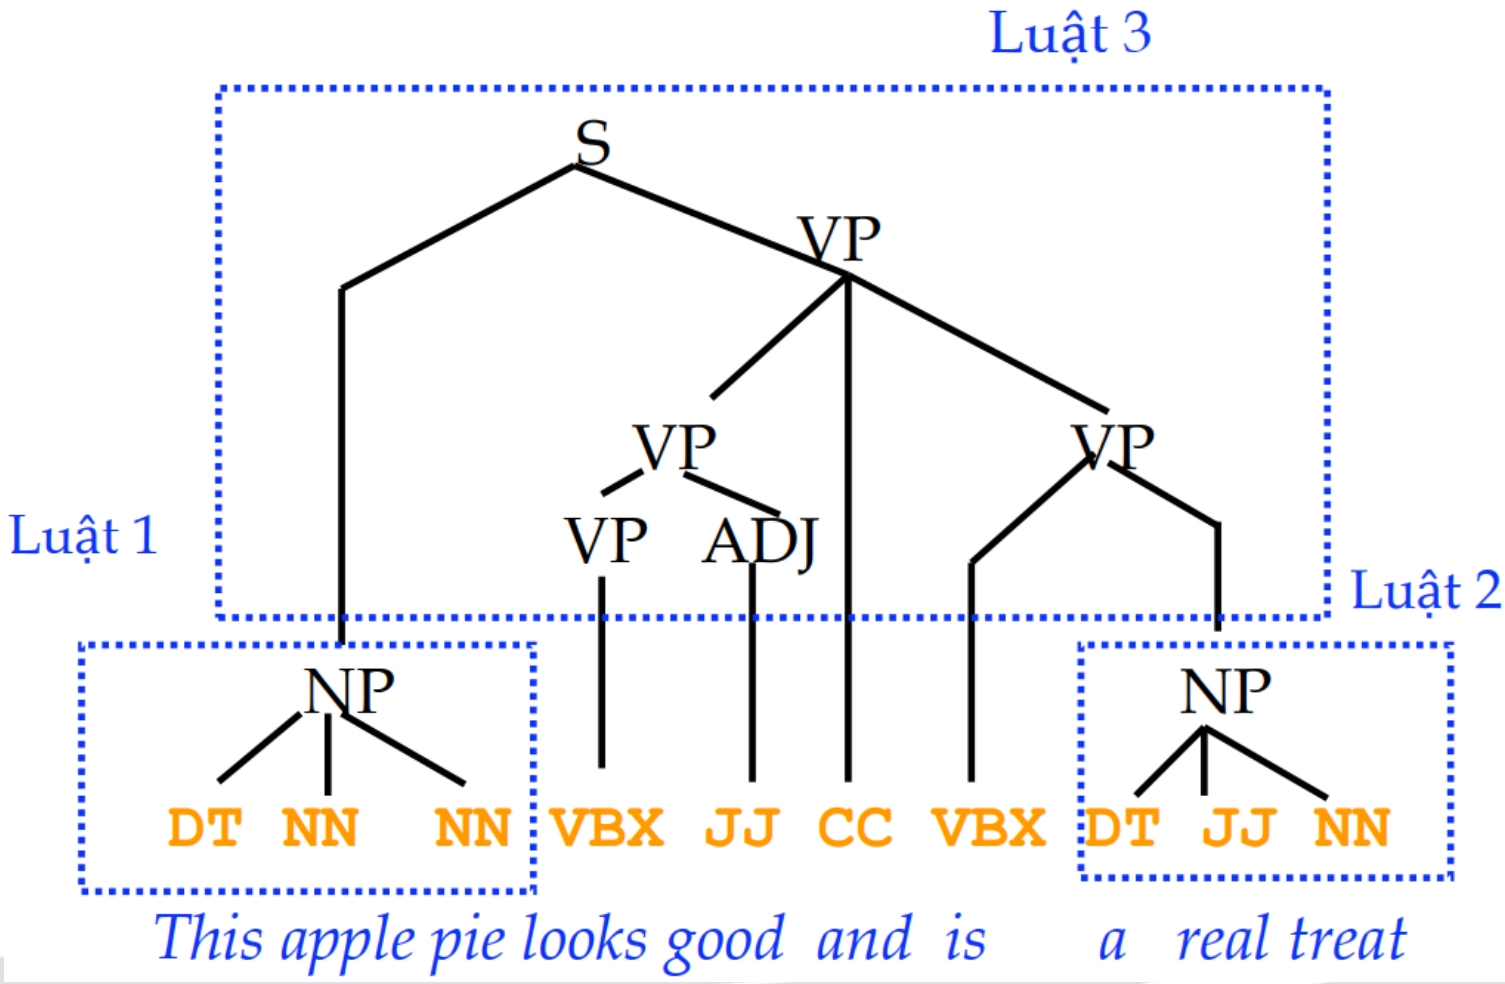
- V có một số loại bổ ngữ nhất định

  → Verb-with-obj, verb-without-obj

- Sự tương thích giữa chủ ngữ và bổ ngữ:
  - John admires honesty
  - Honesty admires John ???
- Nhược điểm:
  - Kích thước tập ngữ pháp tăng
  - Các bài báo của tạp chí Wall Street Journal trong 1 năm: 47219 câu, độ dài trung bình 23 từ, gán nhãn bằng tay: chỉ có 4.7% hay 2232 câu có cùng cấu trúc ngữ pháp

  → Không thể dựa trên việc tìm các cấu trúc cú pháp đúng cho cả câu. Phải xây dựng tập các mẫu ngữ pháp nhỏ

Ví dụ


Luật 3
S
VP
VP
VP
VP
ADJ
Luật 1
Luật 2
NP
NP
DT NN NN
VBX JJ CC VBX
DT JJ NN
This apple pie looks good and is a real treat

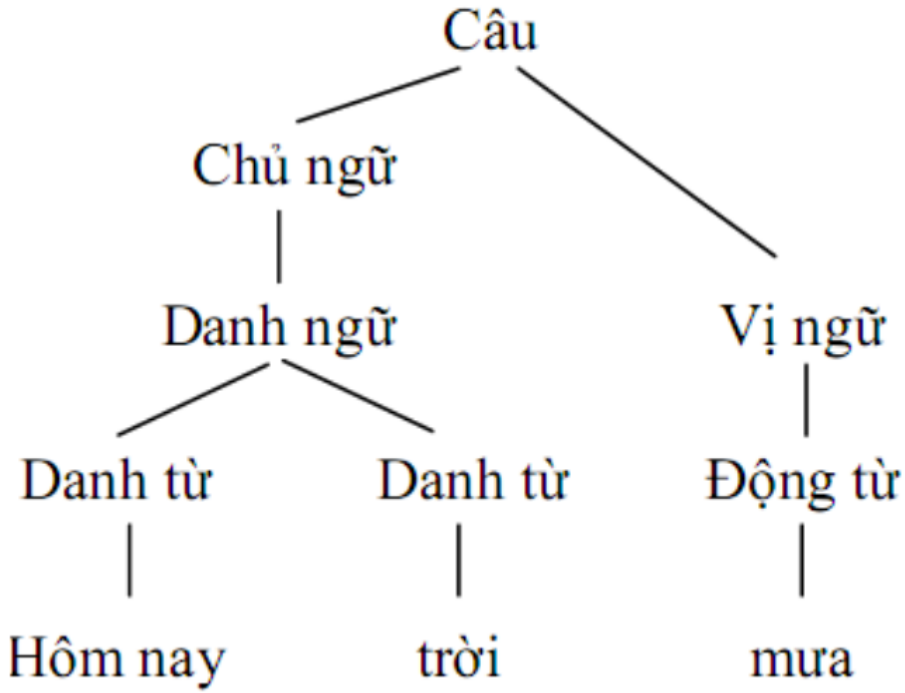
Luật

1. NP→DT NN NN
2. NP→DT JJ NN
3. S→NP VBX JJ CC VBX NP

- Nhóm (NNS, NN) thành NX; (NNP, NNPs)=NPX; (VBP, VBZ, VBD)=VBX;
- Chọn các luật theo tần suất của nó

Ví dụ

1. <Câu>→<Chủ ngữ><Vị ngữ>
2. <Câu>→<Trạng ngữ><Chủ ngữ><Vị ngữ>
3. <Trạng ngữ>→<Phó từ>
4. <Danh ngữ>→<Danh từ><Danh từ>
5. <Chủ ngữ>→<Danh ngữ>
6. <Chủ ngữ>→<Danh từ>
7. <Vị ngữ>→<Động ngữ>
8. <Vị ngữ>→<Động từ>

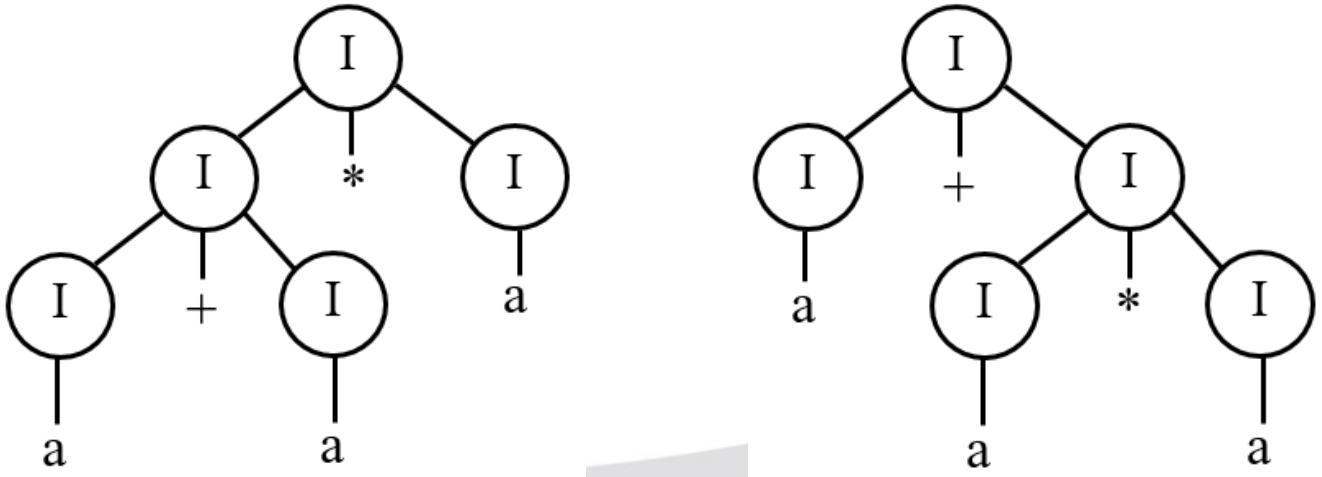


Tính chất cây phân tích cú pháp

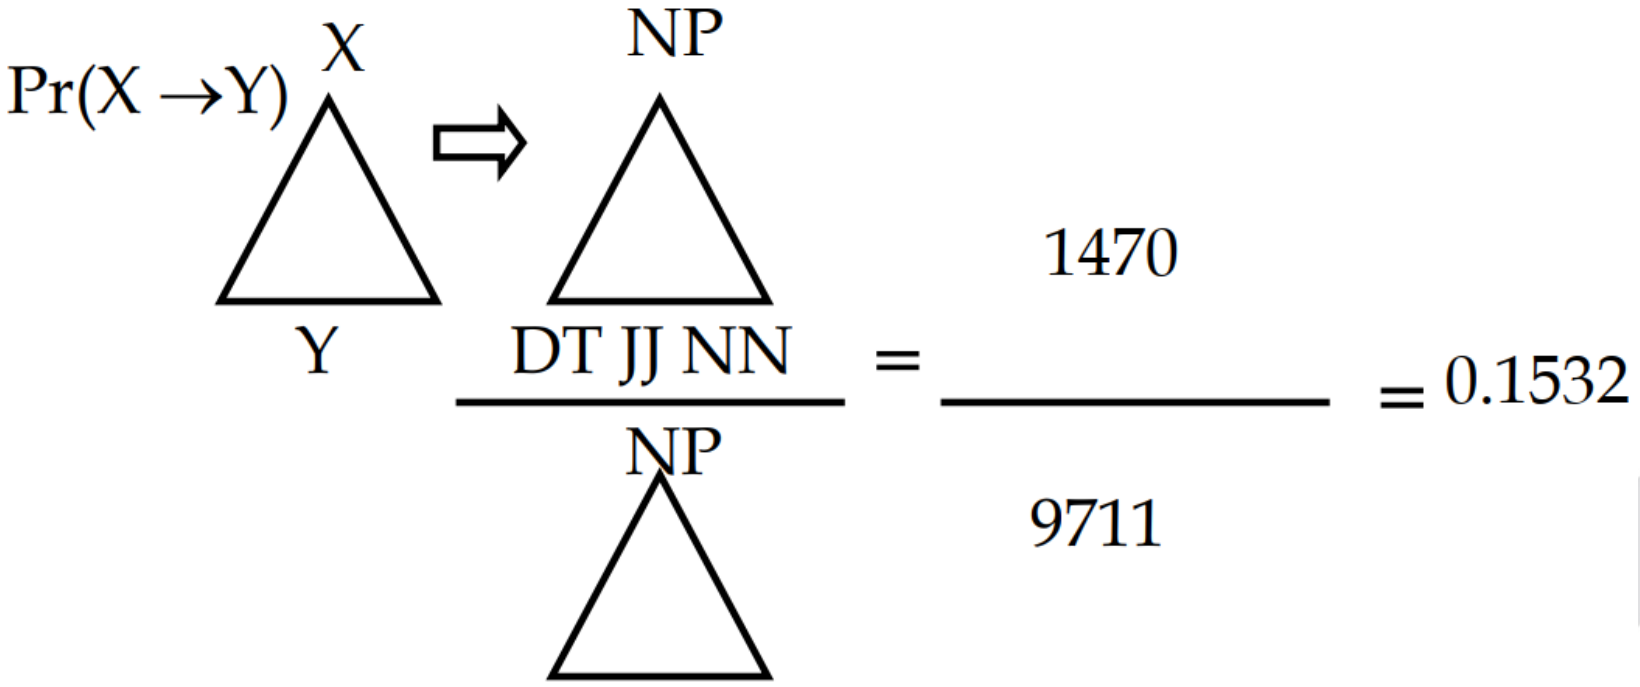
- Nút gốc có nhãn là ký hiệu bắt đầu
- Mỗi một lá có nhãn là một ký hiệu kết thúc hoặc là 1 ký hiệu rỗng €
- Mỗi 1 nút (có nhãn) là một ký hiệu chưa kết thúc
- Nếu A là nhãn của nút không phải là nút cuối, X_1, X_2, …X_n là nhãn các con của nút có nhãn A từ trái sang phải thì
  A → $X_1X_2…X_n$ là luật sinh thuộc tập luật sinh

Sự nhập nhằng

- Một Văn phạm sinh ra nhiều hơn 1 cây phân tích cú pháp cho cùng 1 chuỗi nhập thì gọi là văn phạm nhập nhằng.
- Ví dụ văn phạm G sau đây là không tường minh:
  - P : $I \rightarrow I + I \mid I * I \mid 0 \mid 1 \mid ... \mid 9 \mid a$
  - Xâu a + a * a cho hai cây phân tích:

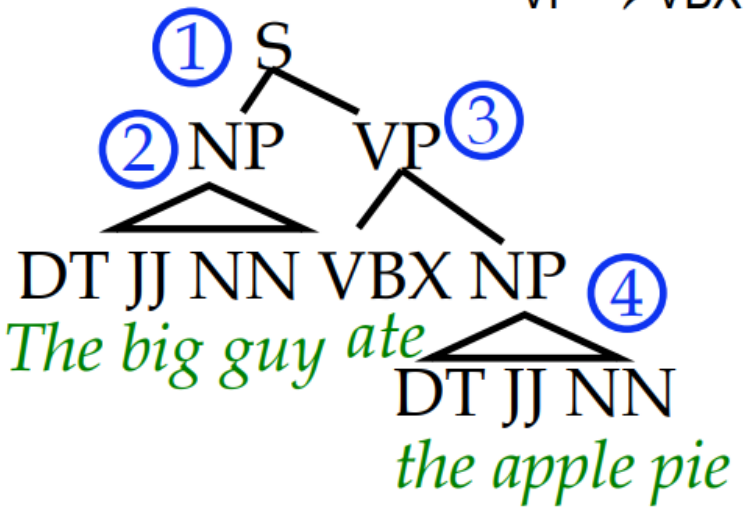


Tính xác suất



Tính xác suất

S → NP VP; 0.35
NP → DT JJ NN; 0.1532
VP → VBX NP; 0.302



Luật áp dụng	*Chuỗi Pr*
1 S →NP VP	0.35
2 NP → DT JJ NN	0.1532 x 0.35 = 0.0536
3 VP → VBX NP	0.302 x 0.0536= 0.0162
4 NP → DT JJ NN	0.1532 x 0.0162=0.0025

Pr = 0.0025

Văn phạm phi ngữ cảnh xác suất

- Một văn phạm phi ngữ cảnh xác suất (Probabilistic Context Free Grammar) gồm các phần thông thường của CFG
- Tập ký hiệu kết thúc $\{w_k\}$, $k = 1, \ldots, V$
- Tập ký hiệu không kết thúc $\{N_i\}$, $i = 1, \ldots, n$
- Ký hiệu khởi đầu N_1
- Tập luật $\{N_i \rightarrow \zeta_j\}$, ζ_j là chuỗi các ký hiệu kết thúc và không kết thúc
- Tập các xác suất của một luật là:

  $\forall i \; \Sigma_j \; P(N_i \rightarrow \zeta_j) = 1$
- Xác suất của một cây cú pháp:

  $P(T) = \Pi_{i=1..n} \; P(r(i))$

Các giả thiết

- Độc lập vị trí: Xác suất 1 cây con không phụ thuộc vào vị trí của các từ của cây con đó ở trong câu

  $\forall k, P(N_{jk}(k+c) \rightarrow \zeta)$ là giống nhau

- Độc lập ngữ cảnh: Xác suất 1 cây con không phụ thuộc vào các từ ngoài cây con đó

  $P(N_{jkl} \rightarrow \zeta \mid$ các từ ngoài khoảng k đến l$) = P(N_{jkl} \rightarrow \zeta)$

- Độc lập tổ tiên: Xác suất 1 cây con không phụ thuộc vào các nút ngoài cây con đó

  $P(N_{jkl} \rightarrow \zeta \mid$ các nút ngoài cây con $N_{jkl}) = P(N_{jkl} \rightarrow \zeta)$

Các thuật toán

- CYK
- Beam search
- Agenda/chart-based search
- …

CYK kết hợp xác suất

- Cấu trúc dữ liệu:
  - Mảng lập trình động π[i,j,A] lưu xác suất lớn nhất của ký hiệu không kết thúc A triển khai thành chuỗi i…j.
  - Backptrs lưu liên kết đến các thành phần trên cây
- Ra: Xác suất lớn nhất của cây

Tính P dựa trên suy diễn

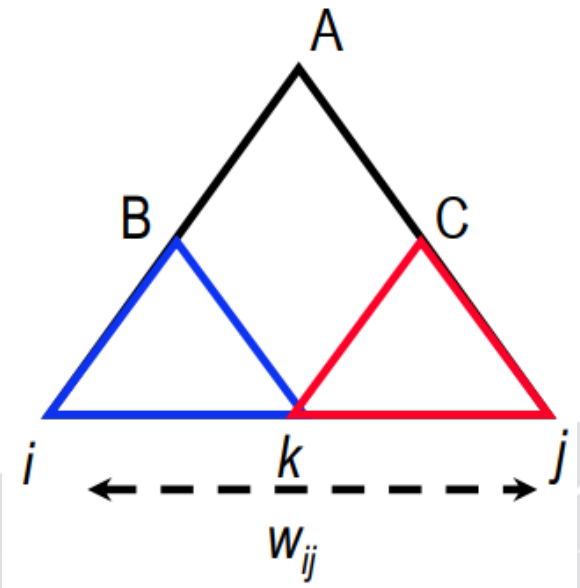
- Trường hợp cơ bản: chỉ có 1 từ đầu vào

  $P(tree) = p(A \rightarrow w_i)$

- Trường hợp đệ qui: Đầu vào là xâu các từ

  $A \Rightarrow^* w_{ij}$ if $\exists k: A \rightarrow BC, B \Rightarrow^* w_{ik}, C \Rightarrow^* w_{kj}, i \leq k \leq j$.

  $p[i,j] = \max(p(A \rightarrow BC) \times p[i,k] \times p[k,j])$.



Tính P dựa trên suy diễn

function CYK(*words*,*grammar*) **returns** *best_parse*

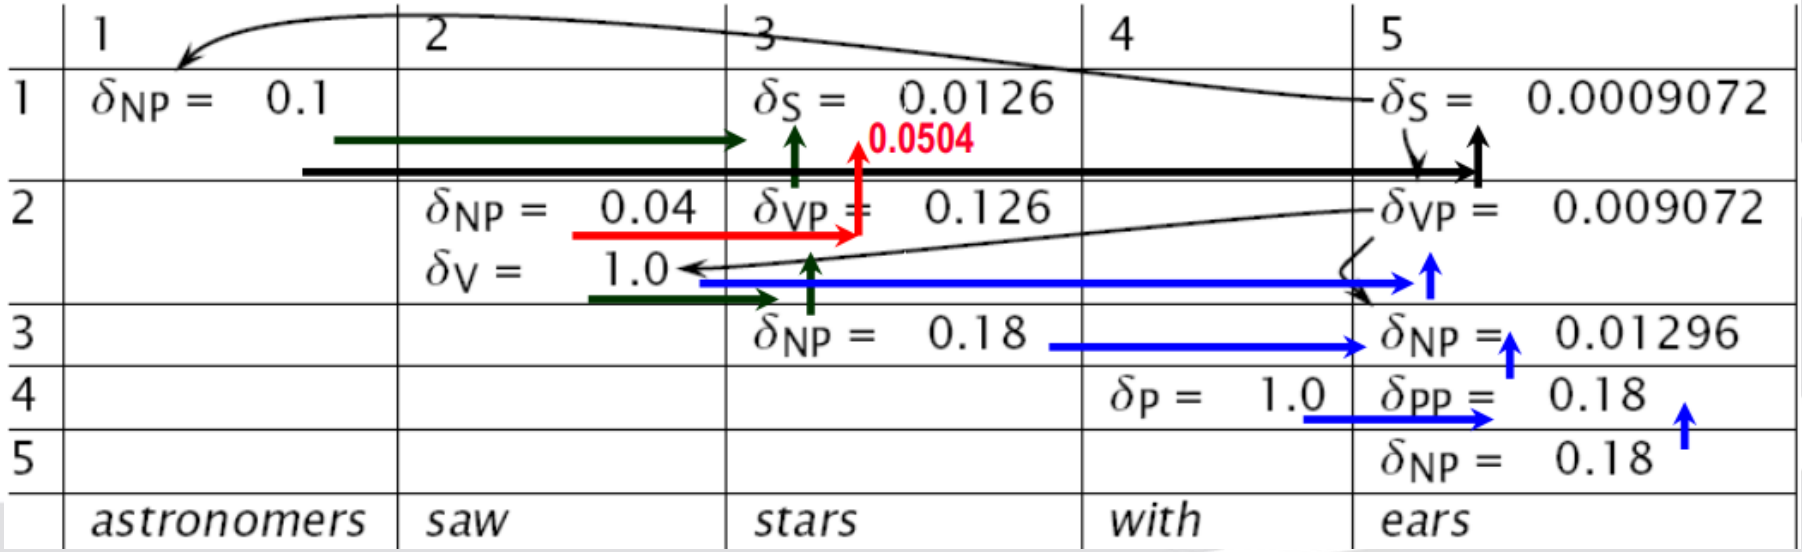
Create and clear *p*[*num_words*,*num_words*,*num_nonterminals*]

```
# base case
for i = 1 to num_words
    for A = 1 to num_nonterminals
        if A → w_i is in grammar then
            π[i, i, A] = P(A → w_i)

# recursive case
for j = 2 to num_words
    for i = 1 to num_words-j+1
        for k = 1 to j-1
            for A = 1 to num_nonterminals
            for B = 1 to num_nonterminals
            for C = 1 to num_nonterminals
                prob = π[i, k, B] × p[i+k, j-k, C] × P(A→BC)
                if (prob > π[i, j, A]) then
                    π[i, j, A] = prob
                    B[i, j, A] = {k, A, B}
```

Tính xác suất Viterbi (thuật toán CYK)

S → NP VP	1.0	NP → NP PP	0.4
PP → P NP	1.0	NP → *astronomers*	0.1
VP → V NP	0.7	NP → *ears*	0.18
VP → VP PP	0.3	NP → *saw*	0.04
P → *with*	1.0	NP → *stars*	0.18
V → *saw*	1.0	NP → *telescopes*	0.1



Ví dụ

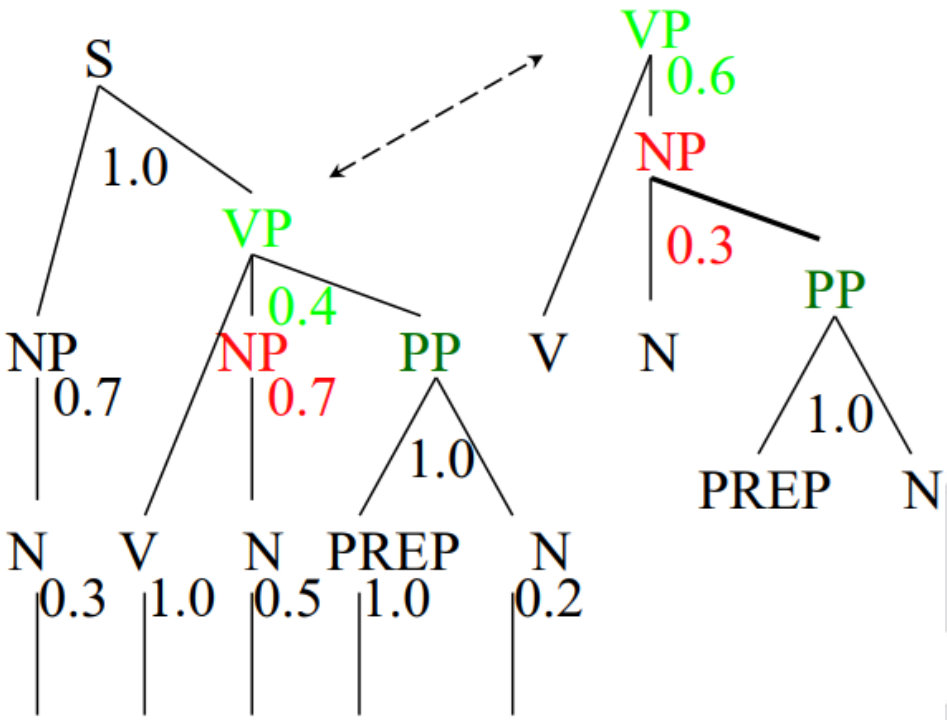
- S → NP VP0.80
- NP → Det N 0.30
- VP → V NP0.20
- V → includes 0.05
- Det → the 0.50
- Det → a 0.40
- N → meal 0.01
- N → flight 0.02

Dùng thuật toán CYK phân tích câu vào:

"The flight includes a meal"

Tính Pr

1.	S → NP VP	1.0
2.	VP → V NP PP	0.4
3.	VP → V NP	0.6
4.	NP → N	0.7
5.	NP → N PP	0.3
6.	PP → PREP N	1.0
7.	N → a_dog	0.3
8.	N → a_cat	0.5
9.	N → a_telescop	0.2
10.	V → saw	1.0
11.	PREP → with	1.0



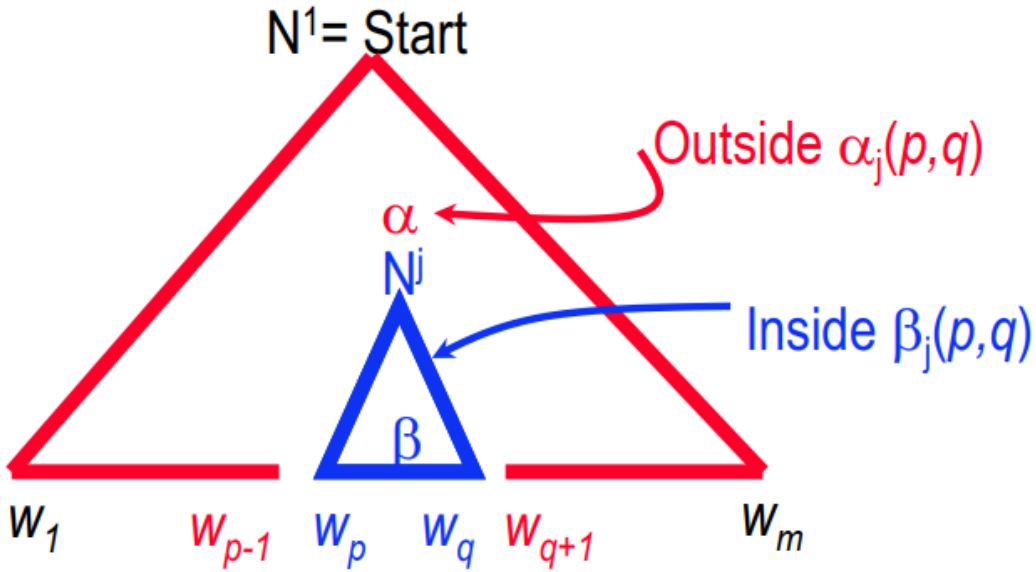
a_dog saw a_cat with a_telescope

$P_l = 1 \times .7 \times .4 \times .3 \times .7 \times 1 \times .5 \times 1 \times 1 \times .2 = .00588$

$P_r = 1 \times .7 \times .6 \times .3 \times .3 \times 1 \times .5 \times 1 \times 1 \times .2 = .00378$

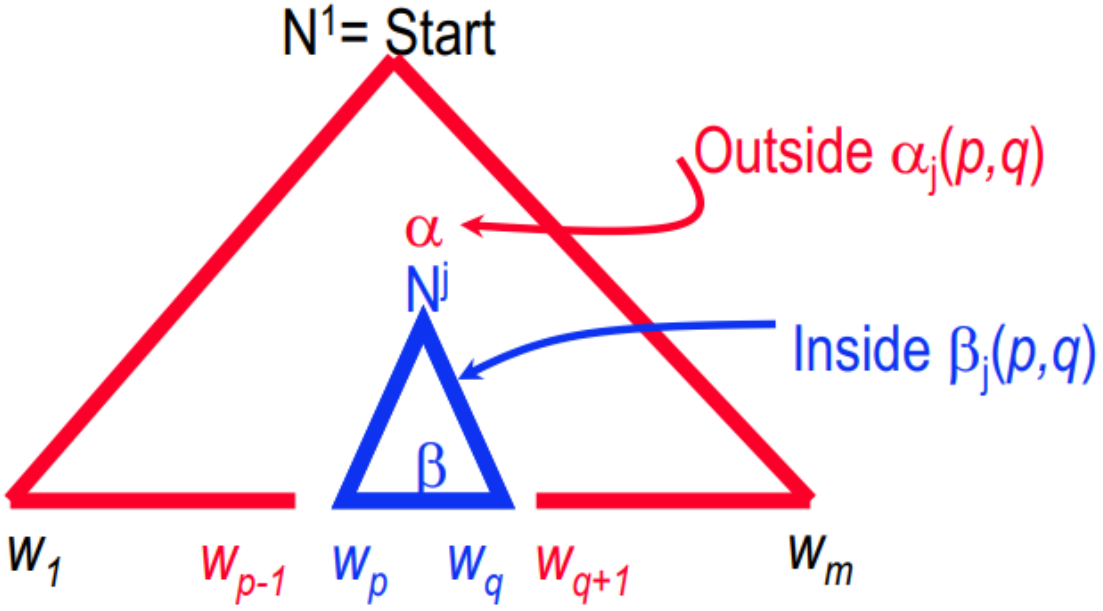
➢ P_l is chosen

Xác suất trong và ngoài



- N_{pq} = ký hiệu không kết thúc N^j trải từ vị trí p đến q trong xâu
- α_j = xác suất ngoài (outside)
- β_j = xác suất trong (inside)
- N^j *phủ* các từ $w_p \ldots w_q$, *nếu* $N^j \Rightarrow^* w_p \ldots w_q$

Xác suất trong và ngoài



$\alpha_j(p,q)=P(w_{1(p-1)}, N_{pq}^{j}, w_{(q+1)m}|G)$

$\beta_j(p,q)=P(w_{pq}|N_{pq}^{j}, G)$

$\alpha_j(p,q)\,\beta_j(p,q) = P(N^1 \Rightarrow^* w_{1m}, N^j \Rightarrow^* w_{pq} \mid G)$

$= P(N^1 \Rightarrow^* w_{1m} \mid G) \bullet P(N^j \Rightarrow^* w_{pq} \mid N^1 \Rightarrow^* w_{1m}, G)$

Tính xác suất của xâu

- Sử dụng thuật toán ***Inside***, 1 thuật toán lập trình động dựa trên xác suất inside

$$P(w_{1m}|G) = P(N^1 \Rightarrow^* w_{1m}|G) = P(w_{1m}|N_{1m}^1, G) = \beta_1(1,m)$$

- Trường hợp cơ bản:

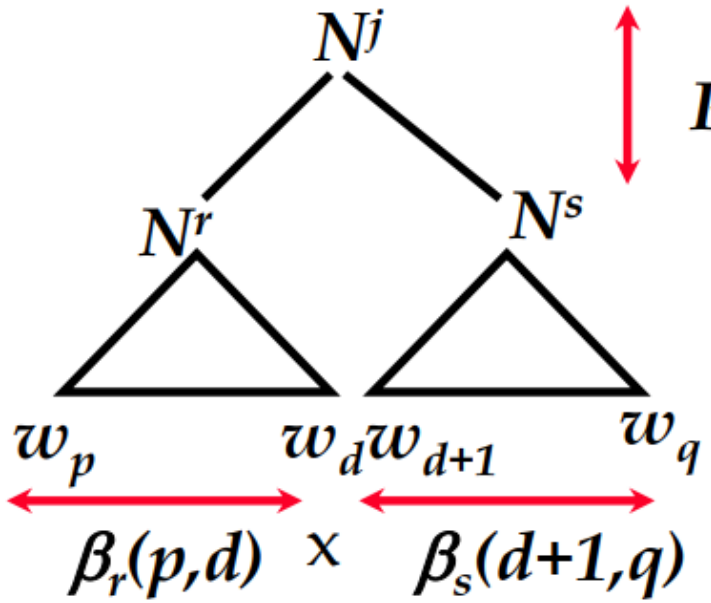
$$\beta_j(k,k) = P(w_k|N_{kk}^j, G) = P(N^j \rightarrow w_k|G)$$

- Suy diễn:

$$\beta_j(p,q) = \Sigma_{r,s}\Sigma_{d\in(p,q-1)} P(N^j \rightarrow N^r N^s)\ \beta_r(p,d)\ \beta_s(d+1,q)$$

Suy diễn

Tính $\beta_j(p,q)$ với p < q – tính trên tất cả các điểm j – thực hiện từ dưới lên

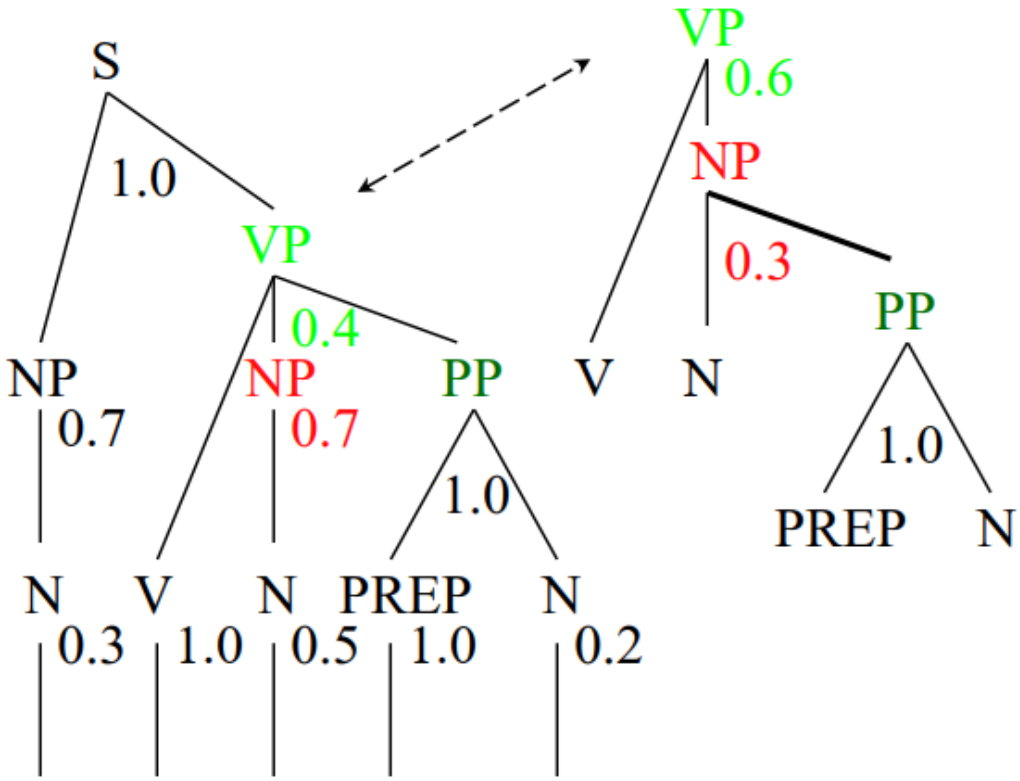


$P(N^j \rightarrow N^r N^s)$

-nhân 3 thành phần, tính tổng theo *j*, *r*,*s*.

Ví dụ

1.	S → NP VP	1.0
2.	VP → V NP PP	0.4
3.	VP → V NP	0.6
4.	NP → N	0.7
5.	NP → N PP	0.3
6.	PP → PREP N	1.0
7.	N → a_dog	0.3
8.	N → a_cat	0.5
9.	N → a_telescope	0.2
10.	V → saw	1.0
11.	PREP → with	1.0



P(a_dog saw a_cat with a_telescope) =

1×.7×.4×.3×.7×1×.5×1×1×.2 + ... ×.6... ×.3... = .00588 + .00378 = .00966

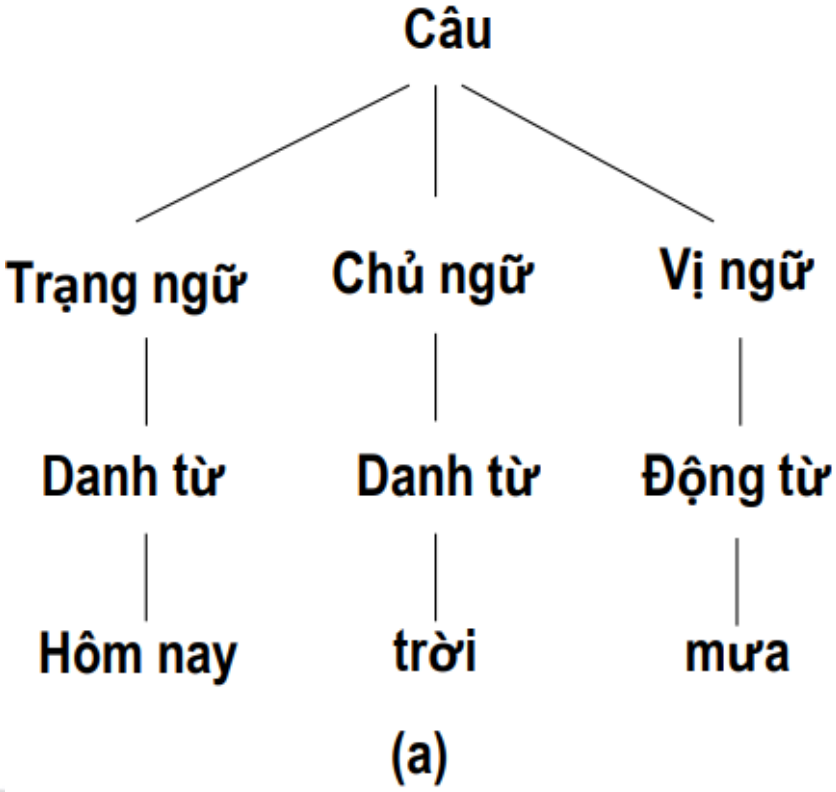
Nhập nhằng trong PTCP tiếng Việt

- 2 loại nhập nhằng cú pháp:
  - Câu có thể hiểu theo nhiều nghĩa khác nhau dẫn đến các cây cú pháp khác nhau.

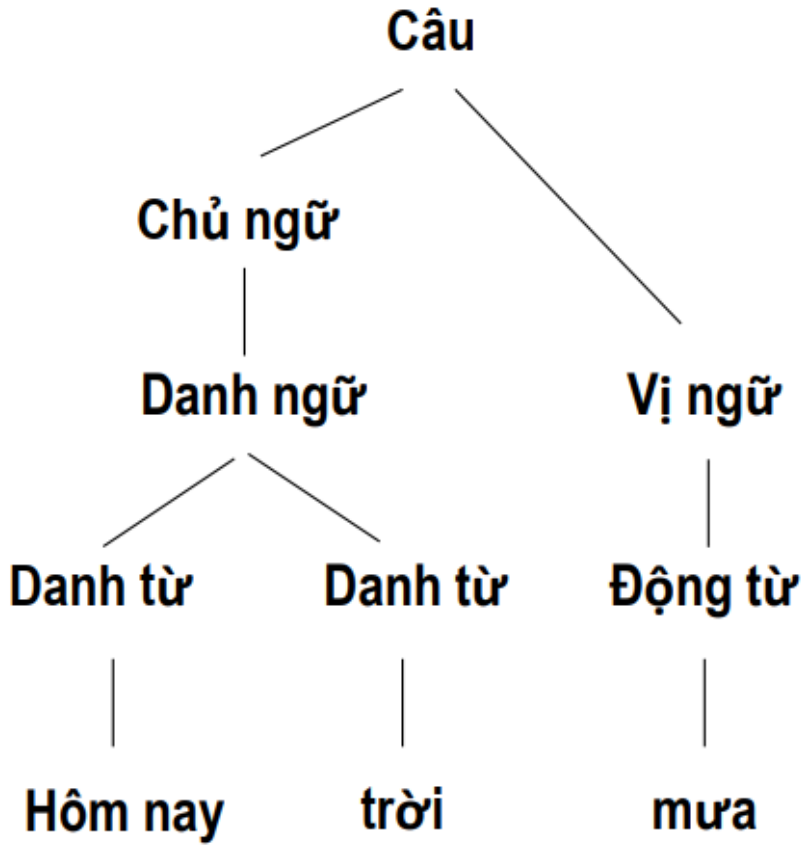
    Ví dụ, câu "*Tôi nhìn thấy anh Hải ở tầng hai*"
  - Câu chỉ có một nghĩa nhưng bộ PTCP vẫn tạo ra nhiều cây cú pháp, trong đó chỉ có một cây đúng.

    Ví dụ, câu "*Hôm nay trời mưa*"

Nhập nhằng trong PTCP tiếng Việt



(a)



(b)

Nhập nhằng trong PTCP tiếng Việt

- Hướng giải quyết:
  - Cách 1: Phân loại chi tiết hơn các nhãn từ loại/ngữ loại

    Thay vì luật:

    <Danh ngữ> → <Danh từ><Danh từ>

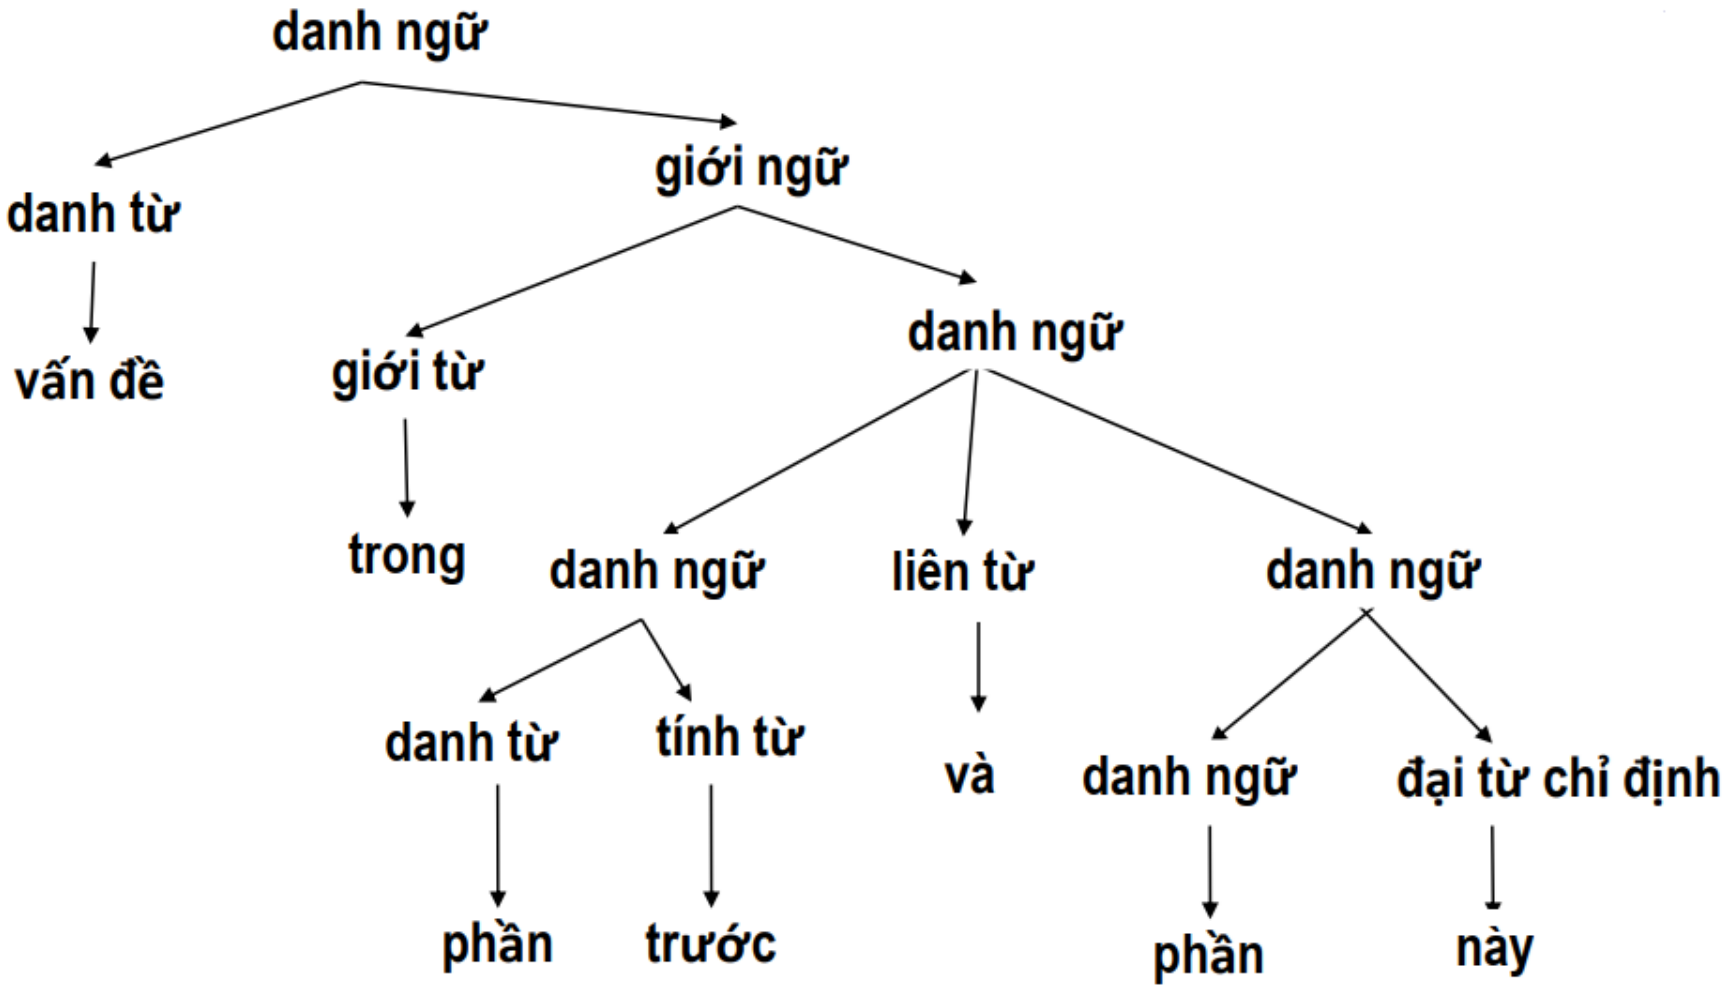
    ta đưa ra luật

    <Danh ngữ> → <Danh từ loại A><Danh từ loại B>.
  - Nhược điểm:
    - Chưa thống nhất trong việc đặt tên các nhãn từ loại/ngữ loại
    - Kích thước tập luật cú pháp tăng lên đáng kể.
    - Phải xây dựng một cách thủ công tập luật cú pháp ứng với tập nhãn từ loại mới → khó thực hiện

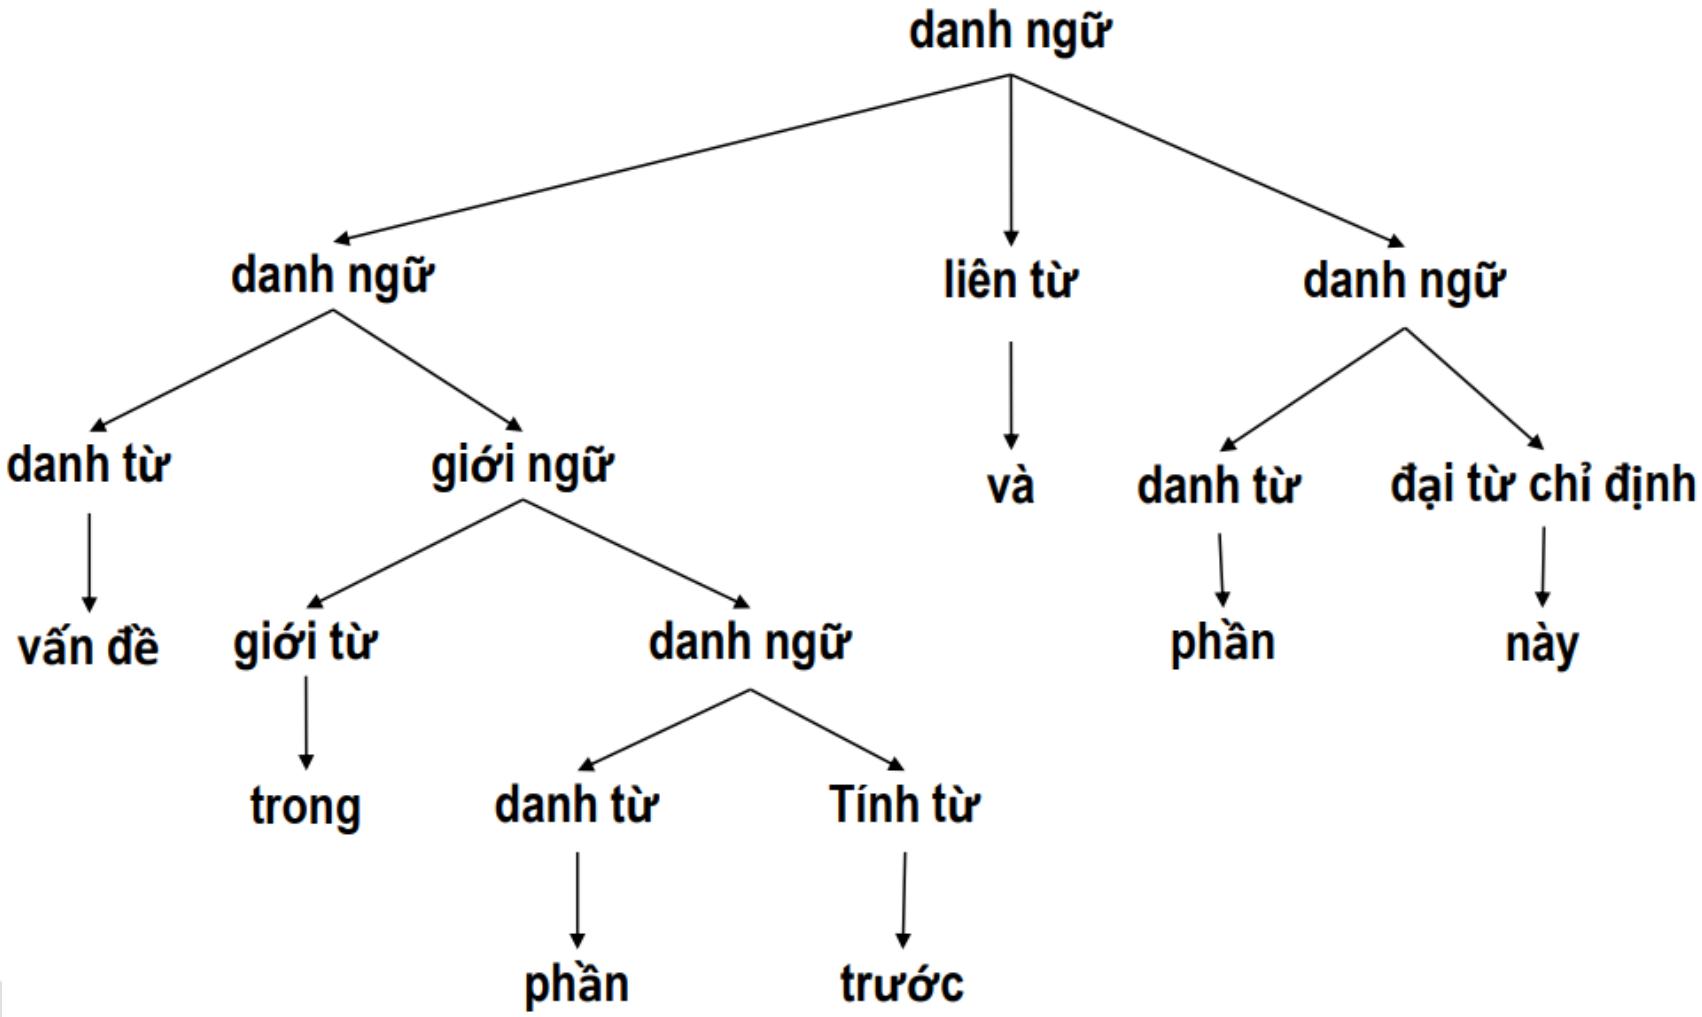
Nhập nhằng trong PTCP tiếng Việt

- Hướng giải quyết:
  - Cách 2: đưa xác suất vào tập luật cú pháp CFG
    - Xử lý được câu “Tôi nhìn thấy anh Hải ở tầng hai”
    - Chưa giải quyết nhập nhằng liên quan đến tính chất của các từ cụ thể.
    - Ví dụ, danh ngữ “vấn đề trong phần trước và phần này”

Nhập nhằng trong PTCP tiếng Việt



Nhập nhằng trong PTCP tiếng Việt



Các từ cụ thể đôi khi ảnh hưởng đến việc PTCP

- Để giải quyết nhập nhằng trong PTCP, đôi khi cần thông tin về từ cụ thể. Ví dụ
  - "*Tôi ăn*" ít khi được chấp nhận là một câu hoàn chỉnh do mang lượng thông tin nhỏ.
  - "*Tôi đang ăn*" dễ được chấp nhận là câu hoàn chỉnh hơn.

  → Phải dựa trên tính chất cụ thể của từ giữ vai trò chính trong câu
- Nhập nhằng do lược bỏ quan hệ từ. Ví dụ
  - có thể nói *bạn tôi*, *con tôi*;
  - không nói *con chó tôi*, *con mèo tôi*.

  →Từ cũng có vai trò quan trọng trong việc PTCP

  →đưa thông tin từ vựng vào văn phạm (làm giàu PCFG)

Làm giàu PCFG

- PCFG từ vựng hóa : PLCFG (Probabilistic Lexicalized CFG, Collins 1997; Charniak 1997)
- Gán từ vựng với các nút của luật
- Cấu trúc Head
  - Mỗi phần tử của parsed *tree* được gắn liền với một *lexical head*
  - Để xác định *head* của một nút trong ta phải xác định trong các nút con, nút nào là *head* (xác định *head* trong vế phải của một luật).

Làm giàu PCFG

VP(dumped) → VBD(dumped) NP(sacks) PP(into) $3*10^{-10}$

VP(dumped) → VBD(dumped) NP(cats) PP(into) $8*10^{-11}$

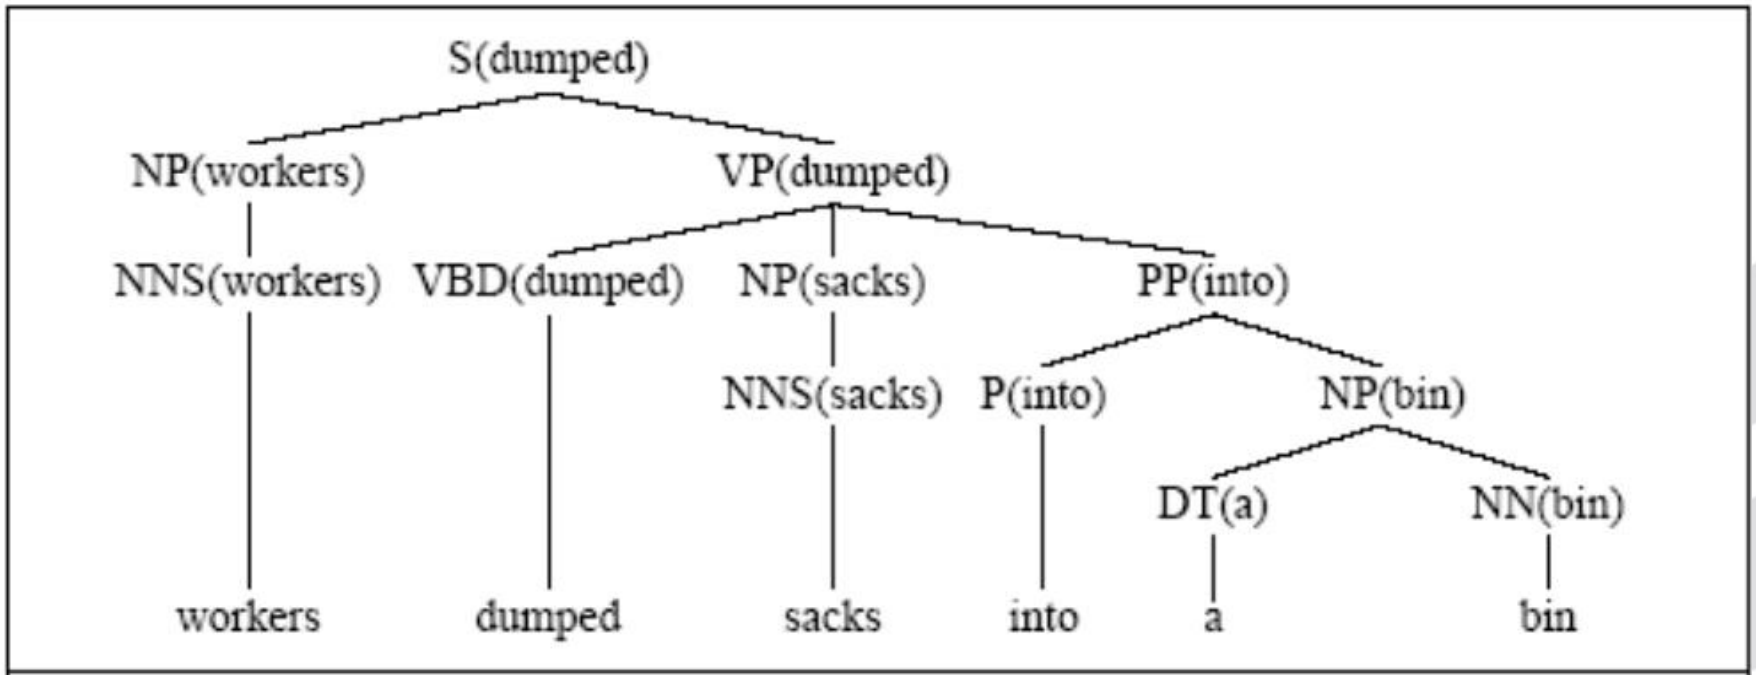


Figure 12.12 A lexicalized tree from Collins (1999).

Hạn chế của PLCFG

VP -> VBD NP PP

VP(dumped) -> VBD(dumped) NP(sacks) PP(into)

- Không có một corpus đủ lớn!
  - Thể hiện hết các trường hợp cú pháp, hết các trường hợp đối với từng từ.

Penn Treebank

- Penn Treebank: tập ngữ liệu có chú giải ngữ pháp, có 1 triệu từ, là nguồn ngữ liệu quan trọng
- Tính thưa:
  - có 965,000 mẫu, nhưng chỉ có 66 mẫu WHADJP, trong đó chỉ có 6 mẫu không là *how much* hoặc *how many*
- Phần lớn các phép xử lý thông minh phụ thuộc vào các thống kê mối quan hệ từ vựng giữa 2 từ liền nhau:

Đánh giá độ chính xác của PTCP

- Độ chính xác của parser được đo qua việc tính xem có bao nhiêu thành phần ngữ pháp trong cây giống với cây chuẩn, gọi là gold-standard reference parses.
- Độ chính xác (Precision) =

$$\% \ \frac{\text{trường hợp hệ gán đúng}}{\text{tổng số trường hợp hệ gán}}$$

(%THợp hệ tính đúng).

- Độ phủ (Recall) =

$$\% \ \frac{\text{số trường hợp hệ gán đúng}}{\text{tổng số trường hợp đúng}}$$

(%THợp hệ tính đúng so với con người).

Các hệ thống PTCP tốt nhất

- CFG (context free grammar):
  - Berkeley : http://nlp.cs.berkeley.edu/software.shtml
  - Charniak: http://bllip.cs.brown.edu/resources.shtml
- HPSG (Head-driven Phrase Structure Grammar)
  - Enju, deepNLP: https://mynlp.github.io/enju/
- Depedency grammar
  - ClearNLP: http://clearnlp.wikispaces.com/depParser
  - Google SyntaxNet: open-source, sử dụng NN, cho câu đúng ngữ pháp,

    https://research.googleblog.com/2016/05/announcing-syntaxnet-worlds-most.html
  - Netbase, cho cả câu twitter

    https://www.codeproject.com/Articles/43372/NetBase-A-Minimal-NET-Database-with-a-Small-SQL
  - Stanford: https://nlp.stanford.edu/software/lex-parser.shtml